

1 Problema clasificării. Tipuri de clasificare

1.1 Învățare supervizată

În contextul învățării supervizate ne este pus la dispoziție un set de date format din perechi (x_i, y_i) , x_i numindu-se *instanță* și y_i *etichetă*. Obiectivul unui algoritm de învățare automată este de a învăța o funcție care să modeleze cât mai bine relația dintre x_i și y_i ce reiese din date. În funcție de variabila y se pot defini 2 tipuri de probleme:

- Clasificare (variabila y este discretă)
- Regresie (variabila y este continuă)

În această lucrare vom aborda doar subiectul clasificării.

1.2 Clasificare binară

Problema clasificării binare ne cere ca pentru o instanță $x \in \mathbb{R}^p$ $p \in \mathbb{N}^*$ dată ca input și o clasă C , să returnăm o valoare $y \in \{0, 1\}$ astfel încât $y = 1$ dacă x face parte din clasa C , sau $y = 0$ în caz contrar. Mai formal, trebuie să găsim o funcție $h : \mathbb{R}^p \rightarrow \{0, 1\}$ definită astfel:

$$h(x) = \begin{cases} 1, & x \in C \\ 0, & \text{altfel.} \end{cases}$$

Această funcție se mai numește model sau ipoteză și scopul unui algoritm de învățare automată este de a oferi un model cât mai bun.

Un exemplu de clasificare binară este ca pentru o imagine să decidem dacă în aceasta se află sau nu o pisică. În acest caz, instanța x va fi un vector ce conține valoarea reală a fiecărui pixel și output-ul va fi $y = 1$ dacă în imagine apare o pisică sau $y = 0$ în caz contrar.

1.3 Clasificare cu clase multiple

La fel ca în cazul clasificării binare, instanța este $x \in \mathbb{R}^p$ $p \in \mathbb{N}^*$, însă, în loc de o singură clasă C , avem o mulțime $\{C_1, C_2, \dots, C_k\}$ $k \in \mathbb{N}^*$ disjuncte, iar obiectivul este să găsim o funcție $h : \mathbb{R}^p \rightarrow \{0, 1, 2, \dots, k\}$ astfel încât:

$$h(x) = \begin{cases} 1, & x \in C_1 \\ 2, & x \in C_2 \\ \vdots & \vdots \\ k, & x \in C_k \\ 0, & \text{altfel.} \end{cases}$$

1.4 Clasificare cu etichete multiple

Pentru o instanță definită la fel ca mai sus $x \in \mathbb{R}^p$ $p \in \mathbb{N}^*$ și o mulțime $C = \{C_1, C_2, \dots, C_k\}$ $k \in \mathbb{N}^*$ vom construi o ipoteză $h : \mathbb{R}^p \rightarrow \{0, 1\}^k$ astfel încât pentru o predicție $y = h(x)$ să avem:


$$y_i = \begin{cases} 1, & x \in C_i \\ 0, & \text{altfel.} \end{cases} \quad i = \overline{1, k}$$

Apare des o confuzie între clasificarea cu etichete multiple și cea cu clase multiple. Diferența fundamentală este ca în prima o instanță poate să aparțină mai multor clase, spre deosebire de cealaltă, în care o instanță este asignată unei singure clase. Totodată, clasificarea binară este un caz particular a clasificării cu etichete multiple atunci când $k = 1$. Detectarea obiectelor face parte din acest tip de clasificare, unde, pentru o imagine, vom marca prezența mai multor obiecte (clase) și nu a unui singur element.

1.5 Învățare multi-instanță

În acest caz, o instanță nu mai este reprezentată de un singur vector de numere reale, ci de o mulțime de astfel de vectori. Fie $X = \{x_1, x_2, \dots, x_k\}$ $k \in \mathbb{N}^*$ $x_i \in \mathbb{R}^{p_i}$ $p_i \in \mathbb{N}^*$ o instanță. O ipoteză h determinată de un algoritm de învățare automată va clasifica întreaga mulțime X și nu fiecare componentă x_i independent.

Problema abordată în această lucrare este una de învățare multi-instanță și de clasificare cu etichete multiple. Un restaurant este reprezentat de o mulțime de imagini și rezultatul este un vector y cu 9 componente, fiecare marcând prezență sau absență celor 9 clase descrise în capitolul introductiv.



$$\rightarrow y = [1, 0, 0, 1, 1, 0, 1, 1, 0]$$

O instanță formată din 12 fotografii și vectorul asociat